

Análise de Pré-processamento de Dados - Dataset Wine

Guilherme Ramos

Nome: Guilherme Ramos

Disciplina: IA

Atividade: Aula 12 - Exercício pré-processamento de dados

a) Análise do Boxplot Original

A análise do primeiro boxplot revela uma extrema disparidade nas escalas das variáveis. A feature **Proline** domina o gráfico com valores muito mais altos (atingindo quase 1750), seguida por **Magnesium**, enquanto as demais ficam espremidas próximas a zero. Isso indica que a média e o desvio padrão variam drasticamente entre os atributos, sendo inviável compará-los diretamente. Apesar da distorção de escala, é possível notar outliers em features como **Magnesium** e **Alcalinity_of_ash**.




Figura 1: Boxplot das features antes da normalização.

b) Análise do Boxplot Normalizado

Após a aplicação do método de normalização (StandardScaler), todas as features passaram a operar na mesma escala (médias próximas a 0 e desvios padrões comparáveis). Com isso, a distribuição dos dados tornou-se visível e comparável. A presença de outliers ficou clara e pode ser observada em diversas variáveis, como: **Malicacid**, **Ash**, **Alcalinity_of_ash**, **Magnesium**, **Proanthocyanins**, **Color_intensity** e **Hue**.




Figura 2: Boxplot das features após normalização.

c) Distribuição de Elementos em cada Classe

O gráfico de barras demonstra a quantidade de instâncias pertencentes a cada uma das três classes do dataset. O conjunto de dados apresenta um leve desbalanceamento, distribuído da seguinte forma:

- **Classe 2:** Majoritária, com aproximadamente 71 instâncias.
- **Classe 1:** Cerca de 59 instâncias.
- **Classe 3:** Minoritária, com cerca de 48 instâncias.




Figura 3: Distribuição de instâncias por classe.

d) Matriz de Correlação e Principais Atributos

A matriz de correlação evidencia como as features interagem entre si, com valores entre -1 e 1. Os atributos que apresentam as **maiores correlações positivas** (fortemente proporcionais) são:

- Total_phenols e Flavanoids: **0.86**.
- Flavanoids e OD280_OD315_of_diluted_wines: **0.79**.
- Total_phenols e OD280_OD315_of_diluted_wines: **0.70**.

Os atributos com as **maiores correlações negativas** (fortemente inversamente proporcionais) são:

- Hue e Malicacid: **-0.56**.
- Nonflavanoid_phenols e Flavanoids: **-0.54**.
- Color_intensity e Hue: **-0.52**.




Figura 4: Matriz de correlação das features.

e) Visualização 2D aplicando PCA

O gráfico de dispersão gerado pelo PCA mostra a projeção dos dados em duas dimensões (PCA1 e PCA2). O método foi altamente eficaz para este dataset, pois é possível observar a formação de três clusters bem definidos que correspondem às três classes de vinho. Há muito

pouca sobreposição entre os grupos, indicando que a variância capturada pelos dois primeiros componentes é suficiente para discriminar as classes de forma clara.




Figura 5: Dispersão 2D das componentes principais.