

Aula 15 - Aprendizado Supervisionado (Parte 2)

Guilherme Ramos

Dataset

Wine Dataset (UCI - <https://archive.ics.uci.edu/dataset/109/wine>)

178 amostras, 13 atributos quimicos, 3 classes de vinho.

Divisao: 70% treino (124 amostras) e 30% teste (54 amostras), aleatoria com random_state=42.

Pre-processamento: normalizacao com StandardScaler (media 0, desvio padrao 1), necessaria para convergencia adequada do SVM, Perceptron e MLP.

1. SVM - Support Vector Machine

Parametros utilizados:

- kernel='rbf': kernel de funcao de base radial, mapeia os dados para um espaco de maior dimensao permitindo separacao nao-linear entre as classes.
- C=1.0: parametro de regularizacao. Controla o trade-off entre maximizar a margem e minimizar erros de classificacao. Valor maior = menos regularizacao.
- gamma='scale': define o raio de influencia de cada amostra de suporte. Com 'scale', $\gamma = 1 / (n_features * X.var())$, se ajusta automaticamente ao dataset.
- random_state=42: semente para reproducibilidade.

Resultado: 53/54 acertos | Acuracia: 98.15%

2. Perceptron

Parametros utilizados:

- max_iter=1000: numero maximo de passagens pelo dataset de treino (epocas). Garante que o algoritmo tenha iteracoes suficientes para convergir.
- eta0=0.1: taxa de aprendizado. Controla o tamanho do passo na atualizacao dos pesos. Valor moderado evita oscilacao e divergencia.
- tol=1e-3: criterio de parada. O treinamento encerra quando a reducao de loss entre epocas consecutivas for menor que este valor.
- random_state=42: semente para reproducibilidade.

Resultado: 53/54 acertos | Acuracia: 98.15%

3. MLP - Multi-Layer Perceptron


Parametros utilizados:

- hidden_layer_sizes=(100, 50): duas camadas ocultas com 100 e 50 neuronios respectivamente. Permite aprender representacoes hierarquicas dos dados.
- activation='relu': funcao de ativacao ReLU (Rectified Linear Unit) nas camadas ocultas. Eficiente e evita o problema de gradiente desvanecente.
- solver='adam': otimizador Adam, adaptativo por parametro. Eficiente para datasets de tamanho pequeno/medio e converge rapido.

- `alpha=0.0001`: força da regularização L2 (weight decay), penaliza pesos grandes para reduzir overfitting.
- `learning_rate_init=0.001`: taxa de aprendizado inicial do Adam.
- `max_iter=500`: número máximo de épocas de treinamento.
- `random_state=42`: semente para reproducibilidade.

Resultado: 54/54 acertos | Acurácia: 100.00%

Print da saída do programa



```
21:47 Mon, May 25 2025 ~/IA/Aulas/aula15
[] ~ z aula15
[] ~/github/IA/Aulas/aula15 <ctrl> x ls
  aula15- Exercícios Aprendizado supervisionado2 - prática.pdf  *guilherme_amos_aula15Pratico.py
[] ~/github/IA/Aulas/aula15 <ctrl> x python guilherme_amos_aula15Pratico.py
=====
Dataset: Wine (UCI) | 178 amostras, 13 atributos, 3 classes
Treino: 124 amostras | Teste: 54 amostras
=====
SVM (RBF, C=1.0, gamma=scale)
Acertos: 53/54 | Acurácia: 98.15%
Perceptron (eta=0.1, max_iter=1000)
Acertos: 53/54 | Acurácia: 98.15%
MLP (camadas=[100,50], relu, adam, alpha=0.0001)
Acertos: 54/54 | Acurácia: 100.00%
=====
[] ~/github/IA/Aulas/aula15 <ctrl> x
```