

Aula 15 - Exercício Teórico: Aprendizado Supervisionado (Parte 2)

Guilherme Ramos

Questão 1 (0,5 pt) - Perguntas sobre SVM

O que são vetores de suporte em um SVM?

Vetores de suporte são as amostras de treinamento que ficam mais próximas do hiperplano de separação, ou seja, as que estão na fronteira da margem. São os únicos pontos que influenciam diretamente a posição e orientação do hiperplano. Remover qualquer outra amostra do conjunto de treino não alteraria o modelo final.

O que representa o hiperplano em um SVM?

O hiperplano é a fronteira de decisão que separa as classes no espaço de características. Em um espaço de n dimensões, o hiperplano tem $n-1$ dimensões. Por exemplo, com 2 atributos o hiperplano é uma reta; com 3, é um plano. A equação é: $w \cdot x + b = 0$. Pontos com $w \cdot x + b > 0$ pertencem a uma classe e com $w \cdot x + b < 0$ pertencem a outra.

Qual é o papel da margem em um SVM?

A margem é a distância entre o hiperplano de separação e os vetores de suporte de cada classe. O SVM busca maximizar essa margem, o que aumenta a capacidade de generalização do modelo para dados não vistos. Uma margem maior reduz o risco de overfitting e torna o classificador mais robusto a ruído nos dados.

O que acontece quando os dados não são linearmente separáveis?

Quando os dados não podem ser separados por um hiperplano linear, o SVM usa duas estratégias:

- 1) Soft Margin (parâmetro C): permite que alguns pontos violem a margem, tolerando erros de classificação controlados pelo parâmetro C .
- 2) Kernel Trick: transforma os dados para um espaço de maior dimensionalidade onde eles se tornam linearmente separáveis, usando funções como RBF (Radial Basis Function), polinomial ou sigmoide, sem calcular explicitamente as coordenadas nesse espaço.

Qual a função do parâmetro C em um SVM?

C é o parâmetro de regularização que controla o trade-off entre maximizar a margem e minimizar os erros de classificação no conjunto de treino:

- C grande: penaliza muito os erros, resultando em margem menor e modelo mais ajustado aos dados (risco de overfitting).
- C pequeno: aceita mais erros no treino em troca de uma margem maior, resultando em modelo mais generalista (risco de underfitting).

O valor ideal de C é geralmente encontrado por validação cruzada (cross-validation).

Questão 2 (0,5 pt) - Rede Perceptron

Dataset e codificação

Codificação: Sim/Grandes = 1 | Não/Pequenas = 0 | Doente = 1 | Saudável = 0

Parametros: taxa de aprendizado $\eta = 0,5$ | limiar $\theta = -0,5$ | pesos iniciais $w = [0, 0, 0, 0]$

Regra de ativacao: $\text{saida} = 1$ se $\text{net} \geq \theta$, $\text{saida} = 0$ se $\text{net} < \theta$

Regra de atualizacao: $w_j = w_j + \eta * \text{erro} * x_j$ (erro = alvo - saida)

Nome	Febre	Enjoo	Manchas	Dores	Diagnostico
Joao	1	1	0 (Peq)	1	1 (Doente)
Pedro	0	0	1 (Gra)	0	0 (Saudavel)
Maria	1	1	0 (Peq)	0	0 (Saudavel)
Jose	1	0	1 (Gra)	1	1 (Doente)
Ana	1	0	0 (Peq)	1	0 (Saudavel)
Leila	0	0	1 (Gra)	1	1 (Doente)

Treinamento - Epoca 1 (passo a passo)

Pesos iniciais: $w_1=0,0$ $w_2=0,0$ $w_3=0,0$ $w_4=0,0$

Paciente	Entrada x	Net = $\sum(w_i * x_i)$	Condicao	Saida	Alvo	Erro	Atualizacao
Joao	[1,1,0,1]	$0,0+0,0+0,0+0,0 = 0,00$	$0,00 \geq -0,5$	1	1	0	sem atualizacao
Pedro	[0,0,1,0]	$0,0+0,0+0,0+0,0 = 0,00$	$0,00 \geq -0,5$	1	0	-1	$w_3: 0+0,5*(-1)*1 = -0,5$
Maria	[1,1,0,0]	$0*1+0*1+(-0,5)*0+0*0 = 0,00$	$0,00 \geq -0,5$	1	0	-1	$w_1:-0,5$ $w_2:-0,5$ $w=[-0,5,-0,5,0,0]$
Jose	[1,0,1,1]	$-0,5+0,5+0 = -1,00$	$-1,00 < -0,5$	0	1	+1	$w_1:0$ $w_3:0$ $w_4:0,5$ $w=[0,-0,5,0,0,5]$
Ana	[1,0,0,1]	$0+0+0+0,5 = 0,50$	$0,50 \geq -0,5$	1	0	-1	$w_1:-0,5$ $w_4:0$ $w=[-0,5,-0,5,0,0]$
Leila	[0,0,1,1]	$0+0+0+0 = 0,00$	$0,00 \geq -0,5$	1	1	0	sem atualizacao

Pesos ao final da Epoca 1: $w_1=-0,5$ | $w_2=-0,5$ | $w_3=0,0$ | $w_4=0,0$ (4 erros)

Resumo das epocas seguintes

Epoca	w_1 (Febre)	w_2 (Enjoo)	w_3 (Manchas)	w_4 (Dores)	Erros
1	-0,5	-0,5	0,0	0,0	4
2	-1,0	-0,5	-0,5	0,0	4
3	-1,0	-0,5	-0,5	0,5	5
4	-1,0	-0,5	-0,5	1,0	5
5	-1,0	-0,5	-0,5	1,0	3
6+	(-1,0	(-0,5	(-0,5	1,0)	3 (ciclo)

Observacao: O dataset nao e linearmente separavel com os parametros fornecidos. Isso ocorre porque Pedro [0,0,1,0] e Saudavel enquanto Jose [1,0,1,1] e Doente e Leila [0,0,1,1] e Doente - a combinacao de atributos nao permite separacao linear perfeita. O algoritmo entra em ciclo a partir da epoca 5 com pesos estabilizados em $w = [-1,0; -0,5; -0,5; 1,0]$, que e o melhor classificador linear encontrado.

Pesos finais (utilizados para classificacao)

w_1 (Febre) = -1,0 | w_2 (Enjoo) = -0,5 | w_3 (Manchas) = -0,5 | w_4 (Dores) = 1,0 | limiar = -0,5

Teste de novos casos

Luis (nao, nao, pequenas, sim) $\Rightarrow x = [0, 0, 0, 1]$

$$\text{net} = (-1,0)*0 + (-0,5)*0 + (-0,5)*0 + 1,0*1 = +1,0$$

$1,0 \geq -0,5 \Rightarrow \text{saida} = 1 \Rightarrow \text{DOENTE}$

Laura (sim, sim, grandes, sim) $\Rightarrow x = [1, 1, 1, 1]$

$$\text{net} = (-1,0)*1 + (-0,5)*1 + (-0,5)*1 + 1,0*1 = -1,0 + (-0,5) + (-0,5) + 1,0 = -1,0$$

$-1,0 < -0,5 \Rightarrow \text{saida} = 0 \Rightarrow \text{SAUDAVEL}$

Análise: A classificação de Laura como Saudável é uma consequência direta da não-separabilidade linear do dataset. O peso negativo de Febre e Enjoo penaliza fortemente sua entrada, mesmo com todos os atributos iguais a 1. Para melhorar a classificação, seria necessário usar um modelo não-linear como MLP ou SVM com kernel RBF.