

Universidade Federal de São Paulo - UNIFESP

Inteligência Artificial | Aula 16 – Exercício Prático: Implementação de Rede Neural Convolucional (CNN)

Guilherme Bento Ramos – 185226 | Breno Porto Pinheiro do Prado – 185196

Este trabalho foi desenvolvido com auxílio do modelo de linguagem Claude (Anthropic), conforme a Resolução CNPq Nº 2664/2026 de 11 de março de 2026.

Métricas de Classificação

Métrica	Valor
Acurácia	0.9347
Precisão (weighted)	0.9351
Revocação (weighted)	0.9347
F1-Score (weighted)	0.9347
Tempo de treinamento e validação	10 min (GPU NVIDIA)

Métricas por Classe

Classe	Revocação	Precisão	F1	Acertos/Total
Daisy	0.9158	0.9560	0.9355	87/95
Dandelion	0.9556	0.9348	0.9451	129/135
Roses	0.9375	0.9000	0.9184	90/96
Sunflowers	0.9429	0.9519	0.9474	99/105
Tulips	0.9167	0.9322	0.9244	110/120

AUC - Curvas ROC par a par


Par de Classes	AUC
daisy vs dandelion	0.996
dandelion vs roses	0.998
roses vs sunflowers	0.995
sunflowers vs tulips	0.996
tulips vs daisy	0.992

Universidade Federal de São Paulo - UNIFESP

Inteligência Artificial | Aula 16 – Exercício Prático: Implementação de Rede Neural Convolucional (CNN)


Guilherme Bento Ramos – 185226 | Breno Porto Pinheiro do Prado – 185196

Curvas de Acurácia e Loss (Treino vs Validação)




As curvas de acurácia mostram aprendizado consistente: acurácia de treino atinge ~95% e a de validação estabiliza em ~90%, com gap de ~5% indicando overfitting leve controlado pelo early stopping. A loss de validação permanece próxima à de treino ao longo de todo o treinamento, evidenciando boa generalização. O fine-tuning (Fase 2) promoveu melhora adicional na acurácia de validação, confirmando o benefício de descongelar as camadas mais profundas do backbone EfficientNetB0.

Matriz de Confusão - Valores Absolutos e Percentuais




A diagonal principal apresenta valores altos em todas as classes. As principais confusões ocorrem entre espécies botanicamente próximas: tulipas x rosas (6 erros) e daisy x dandelion (5 erros). Dandelion obteve a maior taxa de acerto (95,6%), possivelmente pela morfologia muito distinta (esfera branca de filamentos). Daisy foi a classe com mais confusões relativas (91,6%), sendo 5 imagens confundidas com dandelion — ambas com pétalas brancas e centro amarelo.

Acertos e Erros por Classe (Conjunto de Teste)




O gráfico confirma desempenho consistente em todas as classes. Dandelion registrou o menor número de erros absolutos (6 de 135 imagens, 4,4%), enquanto tulipas apresentou o maior número absoluto (10 de 120, 8,3%). Mesmo assim, todas as classes superaram 91% de acerto, demonstrando que o EfficientNetB0 com transfer learning generalizou bem para o conjunto de teste.

Curvas ROC - Par a Par entre Classes



Todos os pares obtiveram $AUC > 0,99$, demonstrando capacidade discriminativa quase perfeita. O par dandelion vs rosas atingiu $AUC=0,998$ (maior separabilidade), enquanto tulipas vs daisy obteve 0,992 (menor, porém ainda excelente). As curvas ROC concentradas no canto superior esquerdo do gráfico confirmam que o modelo aprendeu representações robustas e separáveis para cada classe.

Grad-CAM - Mapas de Ativação (3 imagens × 5 classes)



Os mapas Grad-CAM revelam atenção nas regiões botanicamente corretas: filamentos radiais do dandelion, pétalas em espiral das rosas, disco escuro dos girassóis e contorno das pétalas das tulipas. A ausência de ativações em fundo ou folhas confirma que o modelo aprendeu características visuais intrínsecas de cada espécie, sem correlações espúrias.

Análise e Interpretação dos Resultados (Item j)

1. Métricas de Classificação

O modelo EfficientNetB0 com transfer learning obteve acurácia de 93,47%, com precisão, revocação e F1-score ponderados de 93,51%, 93,47% e 93,46% respectivamente. Desempenho robusto e equilibrado entre as cinco classes, sem viés significativo. O alto resultado já na primeira época de feature extraction (84,7% de acurácia de validação) demonstra a eficácia dos pesos pré-treinados no ImageNet.

2. Curvas de Acurácia e Loss

A acurácia de treino atingiu ~95% ao final, enquanto a de validação estabilizou em ~90%. O gap de ~5% indica overfitting leve e controlado pelo early stopping. A loss de validação permaneceu próxima à de treino, sinalizando boa generalização. O fine-tuning promoveu melhora adicional, confirmando o benefício de descongelar as camadas mais profundas do backbone.

3. Matriz de Confusão e Acertos por Classe

Dandelion foi a classe com melhor desempenho (95,6%), provavelmente pela morfologia muito distinta. As principais confusões ocorreram entre espécies botanicamente próximas: tulipas × rosas (6 erros) e daisy × dandelion (5 erros). Todas as classes superaram 91% de acerto.

4. Curvas ROC / AUC

Todos os pares apresentaram $AUC > 0,99$. O maior foi dandelion vs rosas (0,998) e o menor tulipas vs daisy (0,992). Valores tão elevados indicam representações robustas e separáveis, com as curvas ROC concentradas próximas ao classificador ótimo.

5. Custo Computacional (Tempo de Treinamento)

Com GPU NVIDIA, o treinamento completo (~40 épocas: 30 de feature extraction + 10 de fine-tuning) foi concluído em 10 minutos, demonstrando o alto impacto do uso de acelerador de hardware. A título de comparação, o mesmo código foi executado previamente em CPU durante 3 horas sem que o processo chegasse a ser concluído, evidenciando a inviabilidade prática do treinamento de redes convolucionais profundas sem GPU.

6. Grad-CAM - Explicabilidade

Os mapas de ativação confirmam que o modelo foca em regiões botanicamente relevantes: filamentos radiais do dandelion, pétalas em espiral das rosas, disco central dos girassóis e contorno das pétalas das tulipas. A ausência de ativações no fundo indica que o modelo aprendeu características visuais intrínsecas de cada espécie, tornando suas decisões interpretáveis e confiáveis.